Κ23α - Ανάπτυξη Λογισμικού Για Πληροφοριακά Συστήματα

Χειμερινό Εξάμηνο 2022–2023

Καθηγητής Ι. Ιωαννίδης Άσκηση 2 – Παράδοση: Κυριακή 11 Δεκεμβρίου 2022

Στο δεύτερο μέρος της εργασίας θα υλοποιηθεί η σύζευξη (join) και η εφαρμογή φίλτρου σε επερωτήσεις (queries) στις οποίες συμμετέχουν περισσότεροι πίνακες με αρκετές στήλες. Συγκεκριμένα θα υλοποιηθεί η ανάλυση επερωτήσεων που χρησιμοποιήθηκε στον προγραμματιστικό διαγωνισμό SIGMOD 2018. Στη συνέχεια αναλύονται τα αρχεία εισόδου και η γλώσσα επερωτήσεων που χρησιμοποιείται.

Διαδικασία

Το πρόγραμμα στην αρχή θα τροφοδοτείται με το σύνολο των σχέσεων (πινάκων) στο standard input. Θα λαμβάνει δηλαδή πολλές γραμμές (διαχωριζόμενες με το χαρακτήρα newline '\n'), όπου κάθε γραμμή θα περιέχει ένα αλφαριθμητικό string που θα αναπαριστά το όνομα αρχείο της συγκεκριμένης σχέσης. Τα αρχεία σχέσεων θα βρίσκονται ήδη σε δυαδική μορφή και δεν απαιτούν parsing. Μπορείτε να χρησιμοποιήσετε το πακέτο που δινόταν στον διαγωνισμό (submission.tar.gz) που περιέχει κώδικα αρχικοποίησης των σχέσεων μέσω mmap στην κύρια μνήμη.

Η δυαδική μορφή μιας σχέσης αποτελείται από την επικεφαλίδα και τα δεδομένα. Η επικεφαλίδα περιέχει τον αριθμό των γραμμών (tuples) και τον αριθμό των στηλών (columns). Το τμήμα των δεδομένων ακολουθεί την επικεφαλίδα και αποθηκεύει όλες τις γραμμές χρησιμοποιώντας αποθήκευση κατά στήλες. Με τον τρόπο αυτό, όλες οι τιμές μιας στήλης αποθηκεύονται στη σειρά, στη συνέχεια ακολουθούν οι τιμές της επόμενης στήλης, κ.ο.κ. Η γενική δυαδική μορφή είναι η εξής, όπου το σύμβολο ΤΟCO σημαίνει γραμμή (tuple) 0, στήλη (column) 0' και το σύμβολο της σωλήνωσης δεν είναι τμήμα της δυαδικής μορφής):

uint64_t numTuples|uint64_t numColumns|uint64_t T0C0|uint64_t
T1C0|...|uint64_t TnC0|uint64_t T0C1|...|uint64_t TnC1|...|uint64_t
TnCm

Μετά την αποστολή του συνόλου των σχέσεων, το πρόγραμμα θα περιμένει να λάβει μία γραμμή που θα περιέχει το αλφαριθμητικό "Done".

Μετά από 1 δευτερόλεπτο, το πρόγραμμα θα ξεκινήσει να λαμβάνει επερωτήσεις.

Οι επερωτήσεις θα έρχονται σε ομάδες (batches). Μία ομάδα επερωτήσεων περιέχει ένα σύνολο από επερωτήσεις σύζευξης (join query) (κάθε γραμμή περιέχει μία επερώτηση). Μια επερώτηση σύζευξης αποτελείται από τρία διαδοχικά μέρη, τα οποία διαχωρίζονται από το σύμβολο σωλήνωσης '|':

• Σχέσεις. Μία λίστα από τις σχέσεις που θα συζευχθούν. Θα δίνονται οι ταυτότητες των σχέσεων, διαχωρισμένες με κενά διαστήματα (' '). Οι ταυτότητες των σχέσεων δίνονται από τη

σειρά με την οποία περάστηκαν οι σχέσεις κατά την πρώτη φάση. Για παράδειγμα, η ταυτότητα 0 αναφέρεται στην πρώτη σχέση.

- Κατηγορήματα (predicates). Κάθε κατηγόρημα διαχωρίζεται με το σύμβολο '&'. Υπάρχουν δύο τύποι κατηγορήματος: κατηγόρημα φίλτρου και κατηγόρημα σύζευξης. Τα κατηγορήματα φίλτρου είναι της μορφής: στήλη φίλτρου + τύπος σύγκρισης (δηλαδή μεγαλύτερο '>', μικρότερο '<', ίσο '=') + ακέραιος αριθμός. Τα κατηγορήματα σύζευξης καθορίζουν τις στήλες στις οποίες οι σχέσεις θα συζευχθούν. Ένα κατηγόρημα σύζευξης αποτελείται από τις στήλες στις συζευγόμενες σχέσεις , συνδεόμενες με το σύμβολο ισότητας ('='). Στα κατηγορήματα η ταυτότητα της σχέσης είναι η σειρά με την οποία ταυτοποιείται στη λίστα των σχέσεων που πρόκειται να συζευχθούν (εμμέσως ορίζεται ως σχέση 0 στα κατηγορήματα η πρώτη σχέση σε μία επερώτηση σύζευξης, σχέση 1 η επόμενη κ.ο.κ.)
- Προβολές. Μία λίστα από στήλες που απαιτούνται για να υπολογιστούν τα αθροίσματα ελέγχου της επερώτησης. Παρομοίως με τα κατηγορήματα σύζευξης, οι στήλες αναφέρονται ως ζεύγη σχέσης-στήλης. Οι προβολες διαχωρίζονται με το χαρακτήρα κενού διαστήματος ('').

```
Παράδειγμα: "0 2 4|0.1=1.2&1.0=2.1&0.1>3000|0.0 1.1"

Μετάφραση σε SQL:

SELECT SUM("0".c0), SUM("1".c1)

FROM r0 "0", r2 "1", r4 "2"

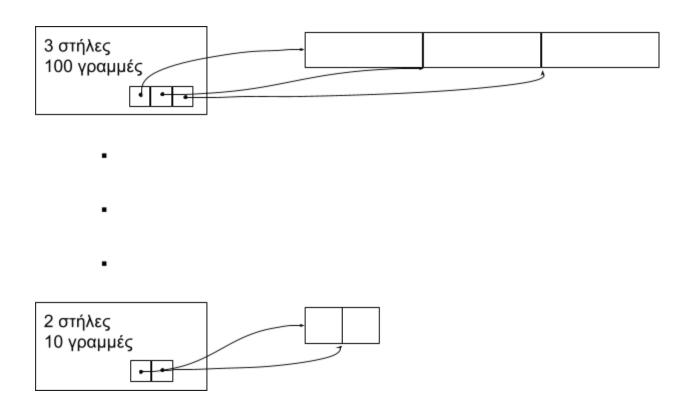
WHERE 0.c1=1.c2 and 1.c0=2.c1 and 0.c1>3000
```

Το τέλος μιας ομάδας επερωτήσεων καθορίζεται με μία γραμμή που περιέχει τον χαρακτήρα 'F'. Το πρόγραμμα στη συνέχεια θα τυπώνει τα αποτελέσματα στο standard output. Για κάθε επερώτηση, το πρόγραμμα θα πρέπει να τυπώνει μία γραμμή που να περιέχει τα αθροίσματα ελέγχου των προβολών διαχωριζόμενα με κενά διαστήματα (π.χ. "42 4711"). Αν δεν υπάρχει γραμμή που να ικανοποιεί τα κατηγορήματα, κάθε άθροισμα ελέγχου θα πρέπει να τυπώνει το αλφαριθμητικό "NULL", όπως στην SQL. Όταν τυπωθούν τα αποτελέσματα, θα δοθεί η επόμενη ομάδα επερωτήσεων.

Τα αθροίσματα ελέγχου δεν θα υπερχειλίζουν αν χρησιμοποιηθούν 64 bit unsigned integers.

Αποθήκευση Σχέσεων στην Μνήμη

Το πρώτο πράγμα που καλείστε να διαχειριστείτε είναι η αποθήκευση των δεδομένων στην μνήμη. Στην αρχή έρχεται ένα πλήθος από file paths (filenames), το κάθε ένα από τα οποία έχει τα δεδομένα κάθε σχέσης. Τα δεδομένα κάθε σχέσης θα πρέπει να διαβαστούν και να αποθηκευτούν στη μνήμη. Για τον λόγο αυτό μπορεί να χρησιμοποιηθεί ένας πίνακας με τόσες θέσεις όσες και οι σχέσεις που θα χρησιμοποιηθούν. Κάθε στοιχείο του πίνακα θα περιέχει μια μεταπληροφορία όπως ο αριθμος των γραμμών αυτού του πίνακα και ο αριθμός των στηλών. Επίσης θα περιέχει και δείκτες στην περιοχή της μνήμης των θέσεων που έχει αποθηκευτεί η κάθε στήλη του. Το πρώτο στοιχείο του πίνακα θα πρέπει να κρατάει την πληροφορία για την πρώτη σχέση το δευτερο για την δεύτερη κ.ο.κ. Η αναπαράσταση της δομής φαίνεται στο παρακάτω σχήμα.



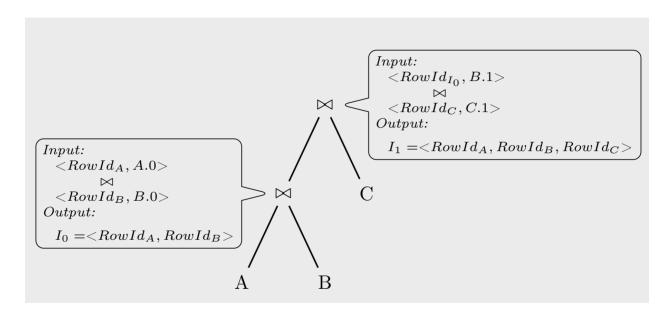
Εκτέλεση Κατηγορημάτων

Εφόσον οι σχέσεις έχουν αποθηκευτεί στη μνήμη, το επόμενο στάδιο είναι να εκτελεστούν τα ερωτήματα. Σε κάθε βήμα θα πρέπει να επιλεγεί και να εκτελεστεί ένα κατηγόρημα (predicate) και το αποτέλεσμα του κατηγορήματος θα πρέπει να ενημερώνει μια οντότητα/δομή η οποία θα κρατάει τα ενδιάμεσα αποτελέσματα που παράγονται σε κάθε βήμα. Πιο αναλυτικά έστω ότι υπάρχει το εξής ερώτημα:

Έστω ότι στην αρχή επιλέγουμε να εκτελέσουμε το κατηγόρημα 0.1>3000. Σε αυτήν την περίπτωση θα πρέπει να σαρώσουμε τη στήλη 1 από την σχέση 0 και να επιστρέψουμε σαν αποτέλεσμα τα RowIDs των γραμμών που ικανοποιούν το κατηγόρημα. Το αποτέλεσμα αυτό θα αποθηκευτεί στην οντότητα που κρατάει τα ενδιάμεσα αποτελέσματα. Η οντότητα αυτή μετα την εκτέλεση του φίλτρου θα κρατάει ένα πίνακα με μια στήλη με τα RowID0 που ικανοποιούν το φίλτρο. Έστω ότι το επόμενο κατηγόρημα που θα εκτελέσουμε είναι το 0.1=1.2, το οποίω υπονοεί μια ζεύξη ισότητας μεταξύ των σχέσεων 0 και 2. Σε αυτήν την περίπτωση παρατηρούμε ότι στα ενδιάμεσα αποτελέσματά μας υπάρχει είδη η σχέση 0. Για τον λόγο αυτό η αναπαράσταση <RowID, value> που θα συμμετέχει στο join για την σχέση 0 θα πρέπει να αναφέρεται σε RowIDs του πίνακα που είναι αποθηκευμένος στην οντότητα αναπαράστασης των ενδιάμεσων αποτελεσμάτων. Αντίθετα, η αναπαράσταση <RowID, value> για τη σχέση 2 θα κατασκευαστεί κατευθείαν από τη στήλη 2.2. Το αποτέλεσμα του Join που θα προκύψει θα έχει RowIDs που αντιστοιχούν στον πίνακα των ενδιάμεσων αποτελεσμάτων ως προς το πρώτο κατηγόρημα (0.1>3000) και RowIDs που θα αντιστοιχούν στην σχέση 2. Με αυτά τα αποτελέσματα θα

ενημερώσουμε των πίνακα των ενδιάμεσων αποτελεσμάτων έτσι ώστε να κρατανε πια ένα πίνακα με 2 στήλες: RowID0|RowID2. Τέλος θα πρέπει να εκτελέσουμε τη ζεύξη 1.0=2.1. Πάλι βλέπουμε ότι στα ενδιάμεσα αποτελέσματα υπάρχει η σχέση 2 ενώ δεν υπάρχει η σχέση 4. Οπότε κάνοντας την ίδια διαδικασία με πριν, η ενημερωμένη οντότητα που προκύπτει θα έχει την μορφή RowID0|RowID2|RowID4 και θα αναφέρεται σε όλες τις γραμμές που ικανοποιούν όλα τα κατηγορήματα.

Στην περίπτωση που ένα κατηγόρημα κάνει ζεύξη ισότητας μεταξύ 2 στηλών του ίδιου πίνακα τότε δεν πρέπει να χρησιμοποιήσουμε τον τελεστή ζεύξης αλλά να σαρώσουμε την σχέση και να επιστρέψουμε τα RowIDs των γραμμών που οι τιμές στα δύο αυτά πεδία είναι ίδιες. Το ίδιο ισχύει αν η ζεύξη αναφέρετε σε στήλες δυο διαφορετικών σχέσεων οι οποίες όμως υπάρχουν και οι δύο στα ενδιάμεσα αποτελέσματα. Τέλος αν η ζεύξη που έχουμε επιλέξει δεν χρησιμοποιεί κανένα από τους πίνακες που βρίσκονται στην οντότητα των ενδιάμεσων αποτελεσμάτων, θα πρέπει να εισάγουμε μια νέα τέτοια οντότητα. Στην περίπτωση που μία επόμενη ζεύξη χρησιμοποιεί σχέσης που βρίσκονται και στην μία και στην άλλη οντότητα, τότε η αναπαράσταση <RowID, value> που θα συμμετάσχει στο join θα αναφέρεται στα RowIDs της μίας και την άλλης οντότητας αντίστοιχα.



Εκτέλεση Αθροισμάτων

Για την εκτέλεση των αθροισμάτων ελέγχου, θα πρέπει να σαρώσουμε τις στήλες που θέλουμε παίρνοντας υπ όψιν μόνο τις γραμμές των οποίων τα RowIDs είναι αποθηκευμένα στον πίνακα των τελικών ενδιάμεσων αποτελεσμάτων.

Γενικά

Ο κώδικάς σας αναμένεται να δουλεύει με όλους τους διαφορετικούς συνδυασμούς ερωτημάτων και κατηγορημάτων, ακόμη και αν δεν αναφέρονται (οι συνδυασμοί) στην περιγραφή της εργασίας.

Προθεσμία παράδοσης: 11/12/2022

Γλώσσα υλοποίησης: C / C++ χωρίς χρήση stl. Περιβάλλον υλοποίησης: Linux (gcc 5.4+).

Παραδοτέα: Παραδοτέα: Η παράδοση της εργασίας θα γίνει με βάση το τελευταιο commit πριν την προθεσμία υποβολής στο git repository σας. **Η χρήση git είναι υποχρεωτική**.

Επιπλέον, εκτός από τον πηγαίο κώδικα, θα παραδώσετε μια σύντομη αναφορά, με τις σχεδιαστικές σας επιλογές καθώς και να εφαρμόσετε ελέγχους ως προς την ορθότητα του λογισμικού με τη χρήση ανάλογων βιβλιοθηκών (Software testing).